




Descenso de gradiente


Autor: Sanchez Sauñe, Cristhian Wiki



Aplicaciones



Aplicaciones



Aplicaciones

Source A: gender, age, hair length, glasses, pose



Source B:
everything
else




Result of combining A and B


Aplicaciones



Intuición



Descenso de gradiente en acción



Un problema de optimización

Problema:

$$\min_w f(w)$$

Solución Iterativa:

$$w_{k+1} = w_k - \lambda_k \nabla f(w_k)$$

donde,

- w_{k+1} es el valor actualizado luego de k iteraciones
- w_k es el valor inicial antes de la iteración k-ésima,
- λ_k es el tamaño de paso,
- $\nabla f(w_k)$ es el gradiente de f .

Algoritmo completo

Cost Function

$$J(\Theta_0, \Theta_1) = \frac{1}{2m} \sum_{i=1}^m [h_{\Theta}(x_i) - y_i]^2$$

↑ ↑
Predicted Value True Value

Gradient Descent

$$\Theta_j = \Theta_j - \alpha \frac{\partial}{\partial \Theta_j} J(\Theta_0, \Theta_1)$$

↑
Learning Rate

Now,

$$\begin{aligned} \frac{\partial}{\partial \Theta} J_{\Theta} &= \frac{\partial}{\partial \Theta} \frac{1}{2m} \sum_{i=1}^m [h_{\Theta}(x_i) - y]^2 \\ &= \frac{1}{m} \sum_{i=1}^m (h_{\Theta}(x_i) - y) \frac{\partial}{\partial \Theta_j} (\Theta x_i - y) \\ &= \frac{1}{m} (h_{\Theta}(x_i) - y) x_i \end{aligned}$$


Therefore,

$$\Theta_j := \Theta_j - \frac{\alpha}{m} \sum_{i=1}^m [(h_{\Theta}(x_i) - y) x_i]$$



Código

```
def gradient_descent(X,y,theta,learning_rate=0.01,iterations=100):  
    '''  
    X      = Matriz de X con unidades de sesgo agregadas  
    y      = Vector de Y  
    theta=Vector de thetas np.random.randn(j,1)  
    learning_rate  
    iterations = número de iteraciones  
  
    Devuelve el vector theta final y la matriz del historial de  
    costos sobre el número de iteraciones  
    '''  
    m = len(y)  
    cost_history = np.zeros(iterations)  
    theta_history = np.zeros((iterations,2))  
    for it in range(iterations):  
  
        prediction = np.dot(X,theta)  
  
        theta = theta -(1/m)*learning_rate*( X.T.dot((prediction - y)))  
        theta_history[it,:] =theta.T  
        cost_history[it] = cal_cost(theta,X,y)  
  
    return theta, cost_history, theta_history
```



Regresión Lineal



Descenso de gradiente en la función de coste

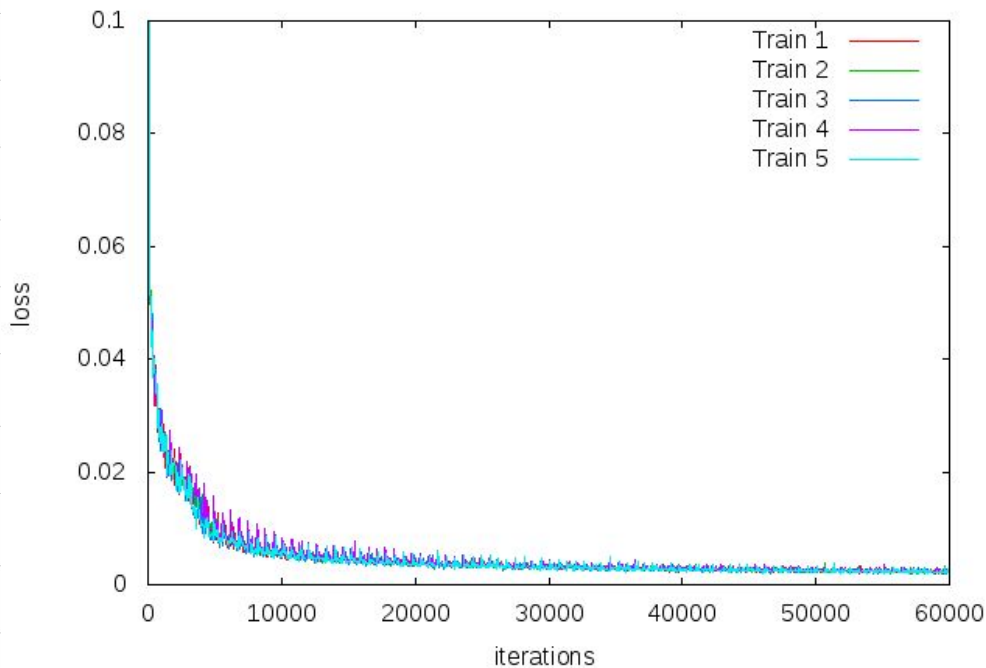


Descenso de gradiente en la función de coste



Error de entrenamiento


Training loss vs. iterations





Complejidad

El costo computacional del descenso del gradiente depende del número de iteraciones que se necesitan para converger. La complejidad del descenso por gradiente es $O(kn^2)$, así que cuando N es muy grande se recomienda utilizar el descenso de gradiente en lugar de la forma cerrada de regresión lineal.

Redes Neuronales



Frameworks



Frameworks

 PyTorch



Deep Learning - DEMO



Demo UNI



Original



Detectron2